


# Busca em Ambientes Complexos

- O que fazer em ambientes parcialmente observáveis ou não-determinísticos?
- Os percepts passam a ter importância
  - Reduzem o possível espaço de estados
  - Permitem verificar o resultado das ações
- A solução passa a ser um **Plano de Contingência**
  - Determinam a ação a ser feita dependendo dos percepts recebidos


# Aspirador de Pó

- Funcionando direito, o problema é resolvido por um busca simples



# Aspirador de Pó Errático


- Ação de aspirar **pode** dar errado
  - Ao ser aplicada em um quadrado sujo, pode aspirar a sujeira do quadrado o vizinho também
  - Ao ser aplicada em um quadrado limpo, pode depositar sujeira no quadrado.
- Cada ação pode resultar em um conjunto de estados ao invés de um estado único



# Aspirador de Pó Errático

- A solução passa a ser um plano de contingência, no qual são usado comandos condicionais para definir as ações

```
Aspira;  
Se estado = 5 então  
    direita;  
    aspira;  
senão  
    nop;
```



- A solução é uma árvore ao invés de uma sequência de ações
- Como achar a solução?

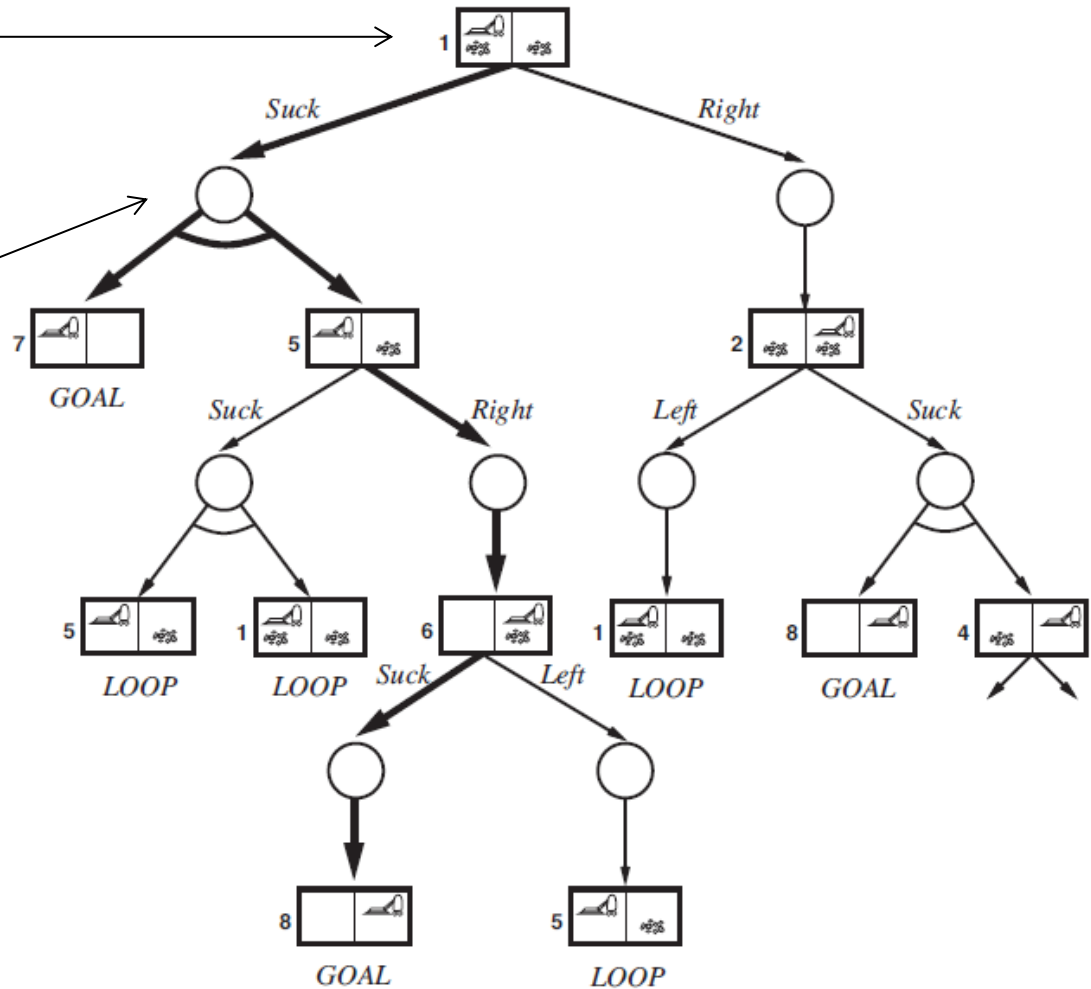
# And-Or Trees

## ■ Nodo Or

- Possíveis ações

## ■ Nodo And

- Possíveis resultados




# And-Or Trees

- A solução é uma subárvore que:
  1. Possui um estado gol em todas as folhas
  2. Especifica uma ação em cada nodo Or
  3. Inclui todos os *branches* dos nodos And
- Observações
  - Deve-se tomar cuidado no tratamento de loops e ações cíclicas
  - É possível intercalar planejamento e ação

# And-Or Trees

Solução:



# And-Or Trees

**function** AND-OR-GRAPH-SEARCH(*problem*) **returns** *a conditional plan, or failure*  
OR-SEARCH(*problem*.INITIAL-STATE, *problem*, [])

---

**function** OR-SEARCH(*state*, *problem*, *path*) **returns** *a conditional plan, or failure*  
if *problem*.GOAL-TEST(*state*) **then return** the empty plan  
if *state* is on *path* **then return failure**  
**for each** *action* **in** *problem*.ACTIONS(*state*) **do**  
    *plan*  $\leftarrow$  AND-SEARCH(RESULTS(*state*, *action*), *problem*, [*state* | *path*])  
    if *plan*  $\neq$  failure **then return** [*action* | *plan*]  
**return failure**

---

**function** AND-SEARCH(*states*, *problem*, *path*) **returns** *a conditional plan, or failure*  
**for each** *s<sub>i</sub>* **in** *states* **do**  
    *plan<sub>i</sub>*  $\leftarrow$  OR-SEARCH(*s<sub>i</sub>*, *problem*, *path*)  
    if *plan<sub>i</sub>* = failure **then return failure**  
**return** [if *s<sub>1</sub>* **then** *plan<sub>1</sub>* **else if** *s<sub>2</sub>* **then** *plan<sub>2</sub>* **else ... if** *s<sub>n-1</sub>* **then** *plan<sub>n-1</sub>* **else** *plan<sub>n</sub>*]

---

**Figure 4.11** An algorithm for searching AND-OR graphs generated by nondeterministic environments. It returns a conditional plan that reaches a goal state in all circumstances. (The notation [*x* | *l*] refers to the list formed by adding object *x* to the front of list *l*.)




# *Sensorless Problems*

- O agente não tem sensores para avaliar o seu estado (**observação parcial**), mas sabe o resultado de suas ações
- Nesse caso, o agente trabalha com conjuntos de estados onde ele pode estar
  - *Belief State* (Estado de Crença)
- A pesquisa é feita sobre o espaço de *belief states* ao invés do espaço de estados

# Sensorless Problems

- Por exemplo, no caso do aspirador de pó, ele pode estar em qualquer dos 8 estados, mas uma ação de ir para a direita restringe o conjunto para 4



# Busca em ambientes complexos

- De forma geral, quando o ambiente é parcialmente observável e/ou estocástico, o algoritmos devem **estimar** o estado
- Estimação Recursiva de Estados
- Duas etapas:
  - **Predição**
    - Qual vai ser o próximo estado dado uma ação  $a$
  - **Observação** (atualização)
    - Qual estado eu estou dado uma observação  $o$

$$b' = \text{Update}(\text{Predict}(b, a), o)$$


# Exemplo: Localização de um robô

## ■ Características:

- Ambiente discreto, mapa conhecido, localização inicial desconhecida, sensores perfeitos, movimentação estocástica


## ■ Sensores retornam $NSW$

- $b_1 = \text{Update}(B_0, NSW)$



# Exemplo: Localização de um robô

- Robô se move
  - $b_2 = \text{Predict}(b_1, \text{move})$
  - Como o movimento é incerto, o resultado são os estados alcançáveis a partir de  $b_1$  pela ação move
- Sensores retornam  $NS$ 
  - $b_3 = \text{Update}(B_2, NS)$



# Exemplo: Localização de um robô

- Estimação Recursiva de Estados:

$$b' = \text{Update}(\text{Predict}(\text{Update}(b_0, \text{NSW}), \text{move}), \text{NS})$$

- Normalmente a estimação recursiva de estados é feita sobre modelos de predição e observação probabilísticos... (Caps. 15 - 17)

# Busca “On-Line”

- Devem intercalar planejamento e ação
  - Ao contrário os algoritmos de busca *off-line* que primeiro planejam depois agem
  - Normalmente necessários em ambientes dinâmicos e/ou estocásticos
  - Problemas de **exploração**

# Busca “On-Line”

- Normalmente o agente tem acesso a:
  - $Ações(s)$
  - $Custo(s, a, s')$  (após aplicar  $a$  e chegar a  $s'$ )
  - $Test\_Goal(s)$
- E, por enquanto, considera-se que os agentes:
  - Sabem onde estão
  - Reconhecem que já passaram por lá
  - Ações são determinísticas
  - Possuem uma heurística:  $h(s)$



# Busca “On-Line”

## ■ Localidade

- Tudo é feito a partir de  $s$ . Não se pode explorar facilmente outra região do espaço de estados

## ■ Se as ações podem ser revertidas

- Ambiente é *safely explorable*

## ■ Algoritmos

- Busca Cega – *Busca em profundidade on-line*
- Busca Local – *Random walk*
- Busca Heurística – *LRTA\**